

HFT_problem_and_delay_analysis

HFT 네트워크 지연 문제 정의 — 큐잉·처리 지연이 핵심인 이유

컴퓨터 네트워크 Module 5 — Group 07 Problem Lead: 김보석 (Kim Boseok)

본 문서는 HFT(High-Frequency Trading) 환경에서 네트워크 지연이 어떻게 발생하고, 4가지 지연 요소 중 **큐잉 지연(d_queue)**과 **처리 지연(d_proc)**이 왜 학부 프로젝트에서 다룰 가치가 있는 핵심 영역인지 이론적으로 정의한다.

목차

[HFT 네트워크 지연 문제 정의 — 큐잉·처리 지연이 핵심인 이유](#)

[목차](#)

[1. HFT란 무엇이고 왜 속도를 중요하게 여기는가](#)

[1.1 정의](#)

[1.2 산업 규모](#)

[1.3 왜 속도를 높이기 위해 경쟁하는가 — 승자 독식 구조](#)

[2. 지연문제](#)

[2.1 가장 돈이 몰리는 시간에 지연이 발생한다.](#)

[2.2 실제 사례: Flash Crash \(2014\)](#)

[3. 왜 d_queue와 d_proc이 핵심인 이유](#)

[3.1 통제가 가능한 변수만 의미 있다.](#)

[3.2 d_queue — 비선형 폭발의 영역](#)

[4. 결론](#)

[References](#)

[팀 작업 흐름](#)

1. HFT란 무엇이고 왜 속도를 중요하게 여기는가

1.1 정의

High-Frequency Trading (HFT, 고빈도 거래)은 사람이 아닌 알고리즘이 매수/매도 의사결정을 내리고, 1초당 수천~수만 건의 주문을 매우 빠른 속도인 μs (마이크로초) 단위로 처리하는 자동 매매 방식이다. 시스템 설계의 모든 결정이 **지연 최소화**에 중점을 둔다는 점에서 일반 거래와 차이가 있다.

1.2 산업 규모

- 미국 주식 시장 거래량의 **약 50%**가 HFT에 의해 발생
- 약 **1ms** 단축이 일일 수익 약 **100만~수백만 달러** 증가에 기여 [3]

1.3 왜 속도를 높이기 위해 경쟁하는가 — 승자 독식 구조

가격 변동이 발생하는 순간 첫 번째로 도착한 주문만 수익을 독점하는 구조이다. 1μs 늦으면 다른 붓이 그 가격을 이미 가져간다. 핵심은 평균 지연이 아니라 실패할 확률인 Tail Latency (P99, P99.9) 이다. 평균이 100μs라도 한번이라도 200ms가 나오면, 평균이 아무리 좋아도 사실상 사용 불가능한 신호가 된다.

HFT는 평균이 아니라 꼬리가 시스템을 결정한다. 본 프로젝트가 평균 RTT보다 P99에 주목하는 이유.

2. 지연문제

2.1 가장 돈이 몰리는 시간에 지연이 발생한다.

1. 시장 변동성 폭발 (FOMC 발표, 실적 시즌, 지정학적 이벤트) → 차익거래 기회 폭발
2. 모든 알고리즘 주문 폭증 → 네트워크 트래픽 과도 → 큐잉 지연 폭발 + 패킷 손실 가능성 증가
즉 수익 기회와 시스템 부담이 비례한다.

2.2 실제 사례: Flash Crash (2014)

- 거래 폭주 발생
- 일부 거래소 시스템에서 큐잉 지연 급증 → 호가 정보 지연 도달
- 주문이 처리되지 못하고 밀려 있는 상태로 시장이 마비됨
- 미 국채 10년물 금리 10여 분 만에 33~34bp 급락 후 곧바로 전액 회복 [1]

3. 왜 d_queue와 d_proc이 핵심인 이유

4가지 중 큐잉·처리 지연에 집중하는 이유

3.1 통제가 가능한 변수만 의미 있다.

지연	통제 수단	프로젝트 적합성
d_prop	거리 단축 — Co-location, 직선 광케이블, 마이크로웨이브	인프라/부동산 영역이기에 상수 취급
d_trans	빠른 인터넷 속도 — 10/40/100 GbE	인터넷 속도만 빠르면 되기에 상수 취급
d_proc	커널 바이패스 (DPDK, OpenOnload), FPGA	분석 가능하지만 어려움
d_queue	프로토콜 선택, QoS, 버퍼 관리	코드와 이론이 직접 만나는 지점

d_prop은 빛의 속도가 절대 상한선이며 코드로는 줄일 수 없다. d_trans는 개인이 통제하기 어렵기에 상수취급한다. 반면 d_proc과 d_queue는 소프트웨어 계층의 선택이 직접적으로 영향을 미치

는 부분.


3.2 d_queue — 비선형 폭발의 영역

Packet queueing delay (revisited)

- a : average packet arrival rate
- L : packet length (bits)
- R : link bandwidth (bit transmission rate)

$$\frac{L \cdot a}{R} : \frac{\text{arrival rate of bits}}{\text{service rate of bits}} \quad \text{"traffic intensity"}$$

- $La/R \sim 0$: avg. queueing delay small
- $La/R \rightarrow 1$: avg. queueing delay large
- $La/R > 1$: more "work" arriving is more than can be serviced - average delay infinite!



Introduction: 1-23

[CN_Module1_Session1_overview]

큐잉 지연이 핵심인 결정적 이유는 **비선형성**이다.

강의자료의 내용 $La/R > 1$: more "work" arriving is more than can be serviced - average delay infinite! 처럼 0에 가까울 때에는 지연이 매우 작다가 1에 가까우면 지연이 무한에 가까워진다

핵심 : d_queue는 평균이 작아도 분산이 매우 크다. **평균이 μs 인 시스템이 지연으로 ms~s까지 느껴지는 영역**이 큐잉 지연이며, 해당 부분이 Tail Latency (P99, P99.9) 이다.

4. 결론

본 문서 요약 :

1. **HFT의 약점은 평균 지연이 아닌 변동성이 높을 때의 지연이다.** 평균이 μs 인 시스템이 P99에서 ms로 오르는 순간 시스템 신뢰도가 무너진다.
2. **Tail Latency를 만드는 원인은 $d_{\text{queue}} + d_{\text{proc}}$ 이다.** d_{prop} 와 d_{trans} 는 개인이 해결하기 어렵기 때문에 상수 취급하고, **$d_{\text{queue}} + d_{\text{proc}}$ 가 통제할 수 있는 영역이기 때문에 RTT의 ~95% 이상을 차지한다.**

3. 그러므로 프로토콜 선택(TCP vs UDP)이 HFT 시스템의 대부분을 결정한다. 두 프로토콜의 본질적 차이는 손실이 없을 때는 미미하지만, $\rho \rightarrow 1$ 에서 손실이 발생하는 순간 비대칭적으로 벌어진다. 이 비대칭이 실제 거래소가 시세 데이터에 UDP 멀티캐스트를 채택하는 이유이다.

References

[1] M. Aquilina, E. Budish, P. O'Neill, "Quantifying the High-Frequency Trading 'Arms Race'," The Quarterly Journal of Economics, Vol. 137, No. 1, 2022.

팀 작업 흐름

```
[김보석 - Problem Lead]  본 문서: HFT 도메인 + 4대 지연 + d_queue·d_proc 핵심 이유
    |
    ▼
[손한주 - Simulation Lead] Docker + tc netem 실측 (TCP/UDP 비교)
    |
    ▼
[김정하 - Protocol Lead]  d_proc 절감 기법 (DPDK, OpenOnload, RDMA) 심층 분석
    |
    ▼
[이준서 - Industry Lead]  실제 산업 사례 (NYSE, CME, Cisco, AWS) 매핑
```

김보석 (Problem Lead) | DCCS307 Computer Networks | Module 5 Group 07 | 2026